گزارش دقت شنیدن صدا

چه کارهایی برای فهم دقیق‌تر سخن استاد انجام شد

بازسازی‌شده از ۳۱ قطعهٔ صوتی استاد (۳۲ دقیقه و ۷ ثانیه) با رأی‌گیری شش‌جریانی؛ متن دقیق اسلایدها از خود فایل pptx و درجهٔ اطمینان هر بخش مشخص شده است.

گزارش صادقانهٔ «دقتِ شنیدنِ صدا» — دکتر زادکمالی

این گزارش می‌گوید برای دقیق‌تر فهمیدن حرف‌های استاد چه کارهایی انجام شد،
چه چیزی جواب داد، چه چیزی جواب نداد، و عددهای واقعی چه می‌گویند.
همهٔ مراحل با اسکریپت‌های همین مخزن قابل بازتولید است.

۱) خلاصهٔ نتیجه در یک نگاه

معیار	نسل ۱ (اولیه)	نسل ۲ (دو مدل)	نسل ۳ (رأی‌گیری ۴ جریانی)	نسل ۳ نهایی (۶ جریانی)
روش	یک afftdn+loudnorm، مدل	پیک‌نرمال+RNNoise، دو مدل	۲ پیش‌پردازش × ۲ مدل	+ کانال‌های پیک‌نرمالِ ساده و Hush/DF3
تعداد واژه	۳٬۱۱۳	۴٬۶۴۳	۳٬۶۲۹	۳٬۶۰۰
نرخ واژه‌های موجود در واژه‌نامهٔ فارسی	۰٫۹۴۳	۰٫۹۴۵	۰٫۹۴۹	۰٫۹۴۵ (توافقی ۰٫۹۴۶)
واژه‌های تأییدشده توسط ≥۲ جریان مستقل	—	—	۷۷٫۵٪	۹۰٫۵٪
تعداد تصحیح واژگانی تخصصی	—	—	۸۵ مورد	۹۹ مورد

نکتهٔ مهم و صادقانه: نسل ۳ عمداً «محافظه‌کارتر» است؛ واژه‌هایی را که فقط یک جریان شنیده حذف/کم‌اعتبار می‌کند. به همین دلیل تعداد کل واژه‌ها از نسل ۲ کمتر، ولی دقت و اعتبار متن بیشتر است. برای جزوه، متنِ «توافق‌شده» منتشر می‌شود.

۲) چه چیزهایی امتحان شد که جواب نداد (و چرا)

مسیر	نتیجه
جست‌وجوی کامل ایندکس PyPI (۹۱۱,۳۱۳ بسته) و npm	هیچ بسته‌ای مدل فارسی همراه ندارد
crispasr (۵۳MB)	فقط کد bindings است؛ هیچ مدلی درونش نیست (مدل‌ها باید از HF بیایند)
wenet-stt, rapidspeech, soda-stt, mozilla-voice-stt	بازرسی محتوای wheel: مدل فارسی ندارند (soda-stt فقط پرتغالی برزیل)
هاو همهٔ آینه HuggingFace (hf-mirror, aifasthub, …)	از این محیط مسدودند (خطای اتصال)

مسیر	نتیجه
مدل‌های ggml بزرگ‌تر Whisper روی GitHub	فایل‌ها LFS pointer (۱۳۳ بایت) و دانلود LFS مسدود
PyPI روی deepfilternet	بستهٔ ۰٫۲MB که مدل را از HF می‌گیرد ‹ بی‌فایده
مدل «شنوا» (بهترین مدل فارسی)	فقط روی HF میزبانی می‌شود ‹ دسترسی ندارد

۳) چه چیزهایی جواب داد

الف) کشف اصلی: صدا فوق‌العاده کم‌جان ضبط شده بود.

اندازه‌گیری ۸ کلیپ: RMS بین -۴۷ تا -۵۴ دسی‌بل (میانگین -۵۱)؛ یعنی حدود

۴۰ دسی‌بل پایین‌تر از سطح طبیعی گفتار. این علت اصلی خطاهای مدل بود.

مقایسهٔ A/B روی ۴ کلیپ (اطمینان Vosk):

پیش‌پردازش	اطمینان	واژه‌های تخصصی یافته‌شده
خام	۰٫۸۲۷	۷٫۵
loudnorm	۰٫۸۴۰	۷٫۸
پیک‌نرمال به -۱dBFS	۰٫۸۵۱	۷٫۸
پیک‌نرمال + RNNoise	۰٫۸۴۸	۷٫۵

ب) نویزگیری RNNoise (بستهٔ pyrnnoise — مدل عصبی همراه بسته، بدون نیاز به دانلود).

پ) ترکیب دو مدل فارسی موجود (vosk-small-fa-0.42 و 0.5) به‌جای تکیه بر یکی.

ت) رأی‌گیری چهارجریانی (ROVER) با مهرِ زمانی واژه‌ها — هستهٔ نسل ۳.

۴) کاری که *انجام شد ولی برنده نشد* — و صادقانه گزارش می‌شود

مدل نویزگیری عصبیِ DeepFilterNet3 متا (همان «Hush») را از صفر به پایتون بردم:

• مدل‌های ONNX (۸٫۸ مگابایت) از mah92/hush_cpp با clone فیلترشده گرفته شد
(کندکار می git clone در این محیط مسدود است، ولی raw.githubusercontent).

• کل خط لوله (STFT با پنجرهٔ libdf، فیلتربانک ERB، نرمال‌سازی، سه شبکهٔ ONNX،
فیلتر ISTFT، DeepFilter) در hush_denoise.py پیاده شد.

• در کد نمونهٔ C++ یک خطای علامت پیدا شد: فیلتر DF باید *تفریقی* باشد
(y = x - c·x) نه جمعی. با اصلاح آن، اطمینان از ۰٫۷۱۷ به ۰٫۸۷۱ رسید.

با این حال، RNNoise روی این صدا بهتر بود (میانگین اطمینان ۰٫۸۳۳ در برابر ۰٫۷۱۸
پیش از اصلاح و ۰٫۷۹ پس از آن) — چون مشکل این صدا «نویز شدید» نیست، «سطح خیلی کم» است.

پس Hush به‌عنوان ابزار در مخزن ماند ولی در خط لولهٔ نهایی استفاده نشد.

۵) خط لولهٔ نهایی (نسل ۳، شش جریان) — بیشترین دقتِ در دسترس

فایل .m4a

A: afftdn(nf=-25) + loudnorm Vosk small-fa-0.42

B: کِ نرمال‌پیِ(-1dBFS) + RNNoise Vosk small-fa-0.42

C: کِ نرمال‌پیِ(-1dBFS) + RNNoise Vosk small-fa-0.5

D: afftdn + loudnorm Vosk small-fa-0.5

E: کِ نرمالِ ساده (بدون نویزگیری)پیِ Vosk small-fa-0.42

F: یِ نویزگیر عصبِ Hush/DeepFilterNet3 Vosk small-fa-0.42

هم‌ترازی واژه‌به‌واژه با مهر زمانی (جریان مرجع = پرجزئیات‌ترین)

رأی‌گیری: برنده = بیشترین توافق، سپس بالاترین اطمینان

تصحیح واژگان تخصصی (۹۹ مورد): QRS، دپولاریزاسیون، گین، میلی‌ولت، محور، لید دو، موج دلتا …

متنِ توافقی (۹۰٫۵٪ واژه‌ها با تأیید ≥۲ جریان)

خروجی خام این مرحله: transcript-fa-v3.json / transcript-fa-v3.md (نسخهٔ شش‌جریانی) و transcript-fa-v2.md (نسخهٔ چهارجریانی پیشین) — در JSON، هم متن کامل و هم متن توافقی، به‌همراه رای و اطمینان هر واژه.

۶) شاهدِ عینیِ بهبود

- متن قدیم «وجود موج تا پهنای …» — متن جدید :(QRS پایان بحث) media29
  «وجود موج دلتا». واژهٔ «دلتا» دقیقاً همان موج دلتای سندرم WPW است که در جزوه آمده و حالا از خودِ صدا هم تأیید می‌شود.
- . درجه» بازیابی شده۳۰لید دو» و بازهٔ «بین صفر و منفی » :(محور) media20
- .ولت» و «گین» درست شنیده شدمتر بر ثانیه»، «میلی‌میلی» :(استاندارد ثبت) media13
- در media8، پیش از نرمال‌سازی متن بی‌معنی بود («آرای ام آی») و بعد از آن عبارت معنادار MI و بحث ایسکمی بیرون آمد.
- افزودن دو جریان مستقل دیگر (پیک‌نرمالِ ساده و Hush) در نسل سوم توافق چندجریانی را از ۷۷٫۵٪ به ۹۰٫۵٪ رساند؛ یعنی سهم واژه‌هایی که دو سیستم مستقل جداگانه تأییدشان می‌کنند، نزدیک به یک‌سوم بیشتر شد.

۷) محدودیت‌ها (بدون پرده‌پوشی)

1. هیچ مدل فارسیِ بهتری در دسترسِ این محیط نبود؛ بهبود از راه پردازش سیگنال، ترکیب جریان‌ها و تصحیح واژگانی به‌دست آمد، نه از راه مدل بزرگ‌تر.
2. متن حاصلِ رأی‌گیری (۹۰٫۵٪ واژه‌های تأییدشده) هنوز بی‌خطا نیست؛ روی اصطلاحات تخصصی انگلیسی

.خطا باقی است. برای استناد دقیق، فایل صوتی را بشنوید (RBBB، fragmented QRS، …)

3. نقل‌قول‌های داخل joze-voice.md و joze-kamel.md بازسازی و پاک‌سازی‌شدهٔ گفتار است، نه نقل‌قولِ کلمه‌به‌کلمه؛ هر دو با متن شش‌جریانی بازبینی شده‌اند و در joze-kamel.md درجهٔ اطمینان هر بخش ([اطمینان: بالا]/ [اطمینان: متوسط]/ [اطمینان: کم]) صریحاً علامت خورده است.

4. «نرخ واژه‌های واژه‌نامه‌ای» یک معیار جانشین است، نه WER واقعی — چون متن مرجع انسانی برای این صدا وجود ندارد.

۸) بازتولید

```
bash voice-notes/setup.sh                    # هاها + دانلود مدل‌نصب بسته
python3 voice-notes/fa_pipeline4.py          # ۶ گیری (نسخهٔ نهایی)جریان + رأی
python3 voice-notes/fa_pipeline3.py          # ۴ جریان (نسخهٔ قبلی)
ROVER_DIR=fa4_out ROVER_OUT=transcript-fa-v3 python3 voice-notes/fa_rover_report.py
python3 voice-notes/correct_fa.py --in DIR --out DIR   # تصحیح واژگانی
python3 voice-notes/hush_denoise.py in.wav out.wav     # نویزگیر Hush/DF3 (اختیاری)
```